

第 1 章 第三次作业

作业提交形式为线上提交, 应使用 \LaTeX 独立完成作业电子版, 并提交相应程序.

Deadline: 2022 年 5 月 7 日 23:59.

1.1 基础题

1.1.1 凸函数

利用凸函数的二阶条件证明 $f(x) = \log \sum_{k=1}^n \exp(x_k)$ 是凸函数.

注: 本问题可以讨论, 查阅资料.

解 为了简便书写, 我们记向量函数 $t = [\exp(x_1), \exp(x_2), \dots, \exp(x_n)]^T$. 从而, $f(x)$ 写作如下形式

$$f(x) = \log \mathbf{1}^T t.$$

从而我们得到对应的梯度和 Hessian 矩阵:

$$\begin{aligned}\nabla f(x) &= \frac{1}{\mathbf{1}^T t} [\exp(x_i)]_{1 \times n} = s, \\ \nabla^2 f(x) &= \frac{1}{(\mathbf{1}^T t)^2} [\exp(x_i) (\delta_{ij} (\mathbf{1}^T t) - \exp(x_j))]_{n \times n} = \text{diag}(s) - ss^T.\end{aligned}$$

此处的 $s = t/(\mathbf{1}^T t)$, 可以近似理解为一种特殊的归一化 (这里 $t > 0$, 其实就是在 l^1 意义下的归一化). 注意到有 Cauchy 不等式

$$\sum_i (s_i x_i^2) = \left(\sum_i s_i x_i^2 \right) \left(\sum_i s_i \cdot 1^2 \right) \geq \left(\sum_i 1 \cdot s_i x_i \right)^2.$$

从而 $\nabla^2 f(x) \succeq 0$, 即凸性得证.

1.1.2 梯度下降法

设 $f(x) = \frac{1}{2} x^T Q x + b^T x$ 是正定二次函数, 其中 $Q = \text{diag}(1, 2, 10)$, $b = (1, 0, 0)^T$. 设初始点为 $x_0 = (1, 1, 1)^T$. 使用最速下降法, 用精确线搜索确定步长.

1. 算法的收敛速率是怎样的?
2. 要使 $f(x_T) - f(x^*) < 10^{-10}$, 大约需要多少次迭代?

解

1. 注意到采用精准线搜索确定步长, 我们有:

$$\alpha_k = \frac{(g_k^T g_k)^2}{g_k^T Q g_k}.$$

对应的收敛速率为

$$\frac{f(x_{k+1}) - f(x^*)}{f(x_k) - f(x^*)} \leq \left(1 - \frac{2}{1 + \kappa}\right)^2 = \frac{81}{121}.$$

2. 解方程

$$\left(\frac{81}{121}\right)^T \cdot (f(x_0) - f(x^*)) \leq 10^{-10}. \implies T_{\min} = 63.$$

大约需要 63 次迭代.

1.1.3 强凸与光滑问题判定

设 $\min_x f(x) = \frac{1}{2}\|Ax - y\|^2$, 其中 $A \in \mathbb{R}^{n \times n}$ 是非退化矩阵. 使用梯度下降法求解此问题

$$x_{k+1} = x_k - \alpha \nabla f(x_k),$$

其中 α 为步长.

1. 计算 $f(x)$ 相对于 x 的梯度.
2. 设 $A = \text{diag}(-1, 5)$, 完成以下讨论:
 - 证明 $f(x)$ 是强凸函数, 计算参数 μ .
 - 证明 $f(x)$ 是光滑函数, 计算光滑函数的参数 L .
3. 设 $A = \text{diag}(1, 2)$, 完成以下讨论:
 - 采用固定步长 $\alpha_k = 1/4$ 进行迭代, 求算法的单步下降幅度 $f(x_{k+1}) - f(x_k)$.
 - 采用固定步长进行迭代. 问如果要使迭代序列是下降序列, 步长应满足什么条件?
 - 如果 $f(x_0) - f(x^*) = 1$, 要使 $f(x_k) - f(x^*) < 10^{-3}$, 试估计需要多少次迭代.

解

1. $f(x)$ 相对于 x 的梯度为

$$\nabla = A^T(Ax - y).$$

2. 注意到 Hessian 矩阵

$$\nabla^2 f(x) = A^T A = \text{diag}(1, 25).$$

- 注意到 $\nabla^2 f(x) \succeq I$, 故 $f(x)$ 强凸, 且强凸系数 $\mu = 1$.
- 注意到 $\nabla^2 f(x) \preceq 25I$, 故 $f(x)$ 光滑, 且光滑系数 $L = 1$.

3. 注意到单步改进公式

$$\begin{aligned} f(x_{t+1}) - f(x_t) &= \frac{1}{2}\|x_t - \alpha g_t\|_Q^2 - \frac{1}{2}\|x_t\|_Q^2 - \alpha \langle b, g_t \rangle \\ &= \frac{1}{2}\alpha^2 \|g_t\|_Q^2 - \alpha \langle Qx_t, g_t \rangle - \alpha \langle b, g_t \rangle \\ &= \frac{1}{2}\alpha^2 \|g_t\|_Q^2 - \alpha \langle Qx_t + b, g_t \rangle \\ &= \frac{1}{2}\alpha^2 \|g_t\|_Q^2 - \alpha \|g_t\|^2. \end{aligned}$$

- 代入 $\alpha = 1/4$, 得到单步下降幅度

$$f(x_{k+1}) - f(x_k) = g_k^T \left(\frac{1}{32} A^T A - \frac{1}{4} I \right) g_k.$$

- 令 $f(x_{k+1}) - f(x_k) < 0$ 对于特定条件的 α 取值成立即可。考虑关于 α 的二次函数对于任意参数 g_t 均小于零, 求解恒成立问题下的 α 取值范围:

$$\alpha \in \left[0, \min_{g_t} \frac{2\|g_t\|^2}{\|g_t\|_Q^2} \right] = \left[0, \frac{1}{2} \right].$$

- 采用固定步长需要迭代 25 次, 采用精准线搜索需要迭代 7 次¹.

1.1.4 共轭梯度法性质

设 $f: \mathbb{R}^3 \rightarrow \mathbb{R}$ 连续可微. 使用共轭梯度法优化 $f(x)$, 初始点为 $x^{(0)}$, 迭代序列为 $x^{(k+1)} = x^{(k)} + \alpha_k d_k$, 步长由精确线搜索确定. 如果第一次迭代方向为 $d_0 = (1, -1, 2)^T$, 沿 d_0 精确线搜索得到 $x^{(1)}$ 并且在 $x^{(1)}$ 处

$$\left. \frac{\partial f(x)}{\partial x_1} \right|_{x^{(1)}} = \left. \frac{\partial f(x)}{\partial x_2} \right|_{x^{(1)}} = -2.$$

1. 求 $x^{(1)}$ 处的搜索方向
2. 如果在 $x^{(2)}$ 处梯度长度为 $\|\nabla f(x^{(2)})\| = 1$. 求 $\nabla f(x^{(2)})$.

解

1. 注意到正交性, 有 $g_1^T d_0 = 0$ 立得

$$g_1 = \begin{bmatrix} -2 & -2 & 0 \end{bmatrix}^T.$$

由 Fletcher-Reeves 公式得:

$$d_1 = -g_k + \frac{g_1^T g_1}{g_0^T g_0} = \begin{bmatrix} \frac{10}{3} & \frac{2}{3} & \frac{8}{3} \end{bmatrix}^T.$$

2. 考虑约束

$$\begin{bmatrix} d_0 & d_1 & g_2 \end{bmatrix}^T g_2 = \begin{bmatrix} 0 & 0 & 1 \end{bmatrix}^T$$

解之得

$$g_2 = \pm \frac{1}{\sqrt{3}} \begin{bmatrix} 1 & -1 & -1 \end{bmatrix}^T.$$

1.1.5 共轭梯度法的等价性

设 $f(x) = \frac{1}{2} x^T Q x + b^T x + c$ 是二次函数, Q 是正定矩阵.

1. 给定下降方向 d , 计算精确线搜索确定的步长.

¹这里似乎没有明说, 但看上文应该是讨论的固定步长的情况吧, 考试的时候应该会明确指明 (如果不幸忘了写, 按上下文分析是采用哪一种)。

2. 证明, 在上述问题上, 使用精确线搜索确定步长时, 三种共轭梯度法所确定的点列 $\{x_i\}$ 是相同的.

解

1. 考虑如下情况

$$\frac{\partial}{\partial \alpha} f(x + \alpha d) = \nabla f(x + \alpha d)^T d = (Q(x + \alpha d) + b)^T d = 0.$$

注意到 $Qx + b = \nabla f(x)$, 因此

$$\alpha = \frac{\nabla f(x)^T d}{d^T Q d}.$$

2. 只需要证明两组等价关系即可

- 注意到 $g_k - g_{k-1} = \alpha G d_{k-1}$, 故 Hestenes-Stiefel 公式与 Crowder-Wolfe 公式等价.
- 注意到 $g_k^T d_{k-1} = 0, g_k^T g_{k-1} = 0$ 故 Crowder-Wolfe 公式与 Fletcher-Reeves 公式等价.

从而, 在上述问题上, 使用精确线搜索确定步长时, 三种共轭梯度法所确定的点列 $\{x_i\}$ 是相同的.

1.1.6 共轭梯度法的子空间性质与收敛性

设 $f(x) = \frac{1}{2} x^T Q x + b^T x + c$ 是二次函数, Q 是正定矩阵. 使用共轭梯度法, 证明:

1. 每次迭代的搜索方向 d_i 都可以写成下面向量组的线性组合

$$\{d, Qd, Q^2d, \dots, Q^i d\}.$$

2. 对于第 $i+1$ 次迭代的序列 x_{i+1} , 证明, 对于任意由上述向量线性组合的向量 x' , 都有 $f(x') \geq f(x_{i+1})$.
3. 使用上述结论证明, 共轭梯度法在二次函数 $f(x)$ 上迭代 K 次即可收敛到最优点, 其中 K 是矩阵 Q 的不同的特征值的数目 (number of distinct eigenvalues). (说明, 如果 Q 的特征值为 $1, 3, 3, 5, 5, 7$, 则分离特征值数目为 4 个.)

解

1. 考虑归纳法进行证明

- $k=0$ 时, $d_0 = d \in \text{span}\{d\}$ 成立.
- 假设 $k \leq n$ 时, $d_k \in \text{span}\{d, Qd, \dots, Q^k d\}$ 成立.
- 当 $k = n+1$ 时, 注意到

$$d_{n+1} = -g_{n+1} + \beta d_n = -(g_n + \alpha Q d_n) + \beta d_n \in \text{span}\{d, Qd, \dots, Q^n d\}$$

成立.

因此, 每次迭代的搜索方向 d_i 都可以写成下面向量组的线性组合

$$\{d, Qd, Q^2d, \dots, Q^i d\}.$$

2. 考虑张成空间中扰动

$$\sum_{k=0}^i \alpha_k d_k \triangleq D\alpha.$$

考虑极值点的导数

$$\frac{\partial}{\partial \alpha} f(x_0 + D\alpha) = D^T \nabla f(x) = \mathbf{0}.$$

即共轭梯度法对应的正交性

$$\forall k = 0, 1, \dots, i \quad d_k^T \nabla f(x) = 0.$$

故 $f(\mathbf{x}') \geq f(\mathbf{x}_{i+1})$ 成立

3. 注意到相同特征值对应的向量构成特征子空间, 在同一个特征值对应的特征子空间上迭代一次即可达到最优点, 因此迭代 K 次即可收敛到最优点.

1.1.7 约束优化问题的 KKT 条件

考虑由 PCA 的约束优化问题: 设 \mathbf{x}_i 是一组数据, \mathbf{x}_i 的均值为零, $S = \sum_{i=1}^m \mathbf{x}_i \mathbf{x}_i^T$ 是协方差矩阵, 一般 PCA 问题可以写成:

$$\begin{aligned} \arg \max_V \operatorname{tr}(V^T S V) \\ \text{s.t. } V^T V = I_k \end{aligned}$$

其中 $V \in \mathbb{R}^{n \times k}$, 完成以下问题.

1. 写出其 KKT 条件, 并分析 KKT 点.
2. 如果使用投影梯度法进行求解上述问题, 写出投影公式.

解

1. 构造 Lagrange 函数

$$\mathcal{L} = \operatorname{tr}(V^T S V) + \lambda(V^T V - I_k).$$

对 V, λ 求导, 并令之为 0, 得 V 为 S 的前 k 大的特征值对应的单位特征向量构成的矩阵.

2. 略去, 不在考纲内, 有兴趣的同学可以课后联系李老师或助教.

1.2 思考题

思考以下问题, 了解共轭方向与特征向量的关系

1.2.1 共轭方向与特征向量

思考以下问题, 了解共轭方向与特征向量的关系

1.2.2 共轭方向与特征向量

设 $f(x) = \frac{1}{2}x^T Qx + b^T x$ 是正定二次函数, Q 的特征分解为 $Q = U\Lambda U^T$, 特征值满足 $\lambda_1 > \lambda_2 > \cdots > \lambda_n > 0$, 其对应的特征向量分别为 u_1, \cdots, u_n . 令 x^* 表示 f 的最小值点. 取初始点 x_0 , 并且 $x_0 = x^* + \sum_{i=1}^n \beta_i u_i$ 满足 $\beta_i \neq 0, i = 1, \dots, n$. 构造迭代算法

$$x_{k+1} = x_k - \beta_k u_k$$

1. 证明: 方向组 u_1, \cdots, u_n 是关于 Q 相互共轭的.
2. 对于任意 $k = 1, \dots, n-1$, 求单步改进幅度 $f(x_{k+1}) - f(x_k)$.
3. 如果对于 $k = 1, \dots, n-1$, 每一次迭代的改进幅度 $\delta_k = |f(x_{k+1}) - f(x_k)|$ 都相等, 则步长 β_k 满足什么条件?

1.3 编程题

阅读以下页面内容, 并实现相应算法.

1.3.1 使用 Newton-CG 与 L-BFGS 法求解 LASSO 问题

注: 点击题目会跳转相应网页.

1. Newton-CG 法

阅读理解上述 MATLAB 程序, 实例程序转写成 Python 程序, 并实现 Newton-CG 算法.

2. 应用牛顿-共轭梯度法解逻辑回归问题.

阅读上述程序, 并用 Python 实现上述实例.

3. L-BFGS 算法的 MATLAB 实现.

阅读理解上述 MATLAB 程序, 实例程序转写成 Python 程序, 并实现 L-BFGS 算法.

4. 利用 L-BFGS 方法求解逻辑回归问题.

阅读上述程序, 并用 Python 实现上述实例.