

最优化方法第一次作业

162050127 颜劭铭

目录

1	基础题	2
1.1	Sherman-Morrison 公式	2
1.2	矩阵的子空间	2
1.2.1	列空间、行空间、零空间、左零空间定义	2
1.2.2	秩-零化度定理	3
1.3	矩阵求导	4
1.3.1	公式 1	4
1.3.2	公式 2	4
1.3.3	公式 3	5
1.4	多元正态分布的等高面	5
1.4.1	证明概率密度等高面是椭球面	5
1.4.2	求椭圆方程、长轴、短轴	5
1.5	多元正态分布的简单性质	6
1.5.1	计算 $\mathbb{E}[x] = \mu$	6
1.5.2	计算 $\mathbb{E}[xx^T] = \Sigma + \mu\mu^T$	7
1.5.3	证明 $\mathbb{E}[x^T Ax] = \text{tr}(\Sigma A) + \mu^T A \mu$	8
1.5.4	证明 $\mathbb{E}(X^T A X) = \sigma^2(p-1)$	8
1.6	多元正态分布的极大似然估计	9
1.6.1	推导 μ 和 Σ 的极大似然估计	9
1.6.2	证明 $\bar{X} \sim N(\mu, \frac{1}{n}\Sigma)$	10
1.6.3	证明 \bar{X} 是 μ 的无偏估计	11
1.7	范数的严格凸性	11
1.8	证明：凸函数的局部极小值必然是全空间的极小值	12
1.9	投影的最优性条件	12
1.9.1	计算数据 \mathbf{x}_i 在 \mathbf{L} 的投影所对应的点 $\tilde{\mathbf{x}}$	12
1.9.2	对于目标函数 $\min_w J(\mathbf{w})$ 求最优点满足的最优性条件	12
1.9.3	对于目标函数 $\max_w J(\mathbf{w})$ 求最优点满足的最优性条件	13
1.10	KL 散度的简单介绍	14
1.10.1	验证对称性	14
1.10.2	验证非负性	15
2	编程题	15
2.1	Gauss-Jordan 消元法	15
2.2	凸包的简单应用	16
2.2.1	伪代码	16
2.2.2	C++ 源代码	18

1 基础题

1.1 Sherman-Morrison 公式

由逆矩阵的性质: $(A + xy^T)(A + xy^T)^{-1} = I$, 其中 I 指 $n \times n$ 单位矩阵
所以若要验证该公式:

$$(A + xy^T)^{-1} = A^{-1} - \frac{A^{-1}xy^TA^{-1}}{1 + y^TA^{-1}x}$$

可转化为验证: $(A + xy^T)(A + xy^T)^{-1} = I$
验证过程如下:

$$\begin{aligned} & (A + xy^T)(A + xy^T)^{-1} \\ &= (A + xy^T)\left(A^{-1} - \frac{A^{-1}xy^TA^{-1}}{1 + y^TA^{-1}x}\right) \\ &= AA^{-1} - \frac{AA^{-1}xy^TA^{-1}}{1 + y^TA^{-1}x} + xy^TA^{-1} - \frac{xy^TA^{-1}xy^TA^{-1}}{1 + y^TA^{-1}x} \\ &= AA^{-1} + xy^TA^{-1} - \frac{AA^{-1}xy^TA^{-1} + xy^TA^{-1}xy^TA^{-1}}{1 + y^TA^{-1}x} \\ &= I + xy^TA^{-1} - \frac{xy^TA^{-1} + xy^TA^{-1}xy^TA^{-1}}{1 + y^TA^{-1}x} \\ &= I + xy^TA^{-1} - \frac{x(1 + y^TA^{-1}x)y^TA^{-1}}{1 + y^TA^{-1}x} \\ &= I + xy^TA^{-1} - xy^TA^{-1} \\ &= I \end{aligned}$$

其中 I 指 $n \times n$ 单位矩阵

1.2 矩阵的子空间

1.2.1 列空间、行空间、零空间、左零空间定义

首先, 由于列空间、行空间、零空间、左零空间都是基于矩阵提出的, 因此我们应该在某个矩阵的基础上给出四个基本子空间的定义, 会使得定义更加清晰。

我们假设对于一个 $m \times n$ 的矩阵 A , 他蕴含四个基本子空间: 列空间、行空间、零空间、左零空间。

列空间, 顾名思义, 是由矩阵 A 的 n 个 m 维列向量长成, 我们用 $C(A)$ 表示。

行空间, 由矩阵 A 的 m 个 n 维行向量长成, 我们用 $R(A)$ 表示。

由于 A 的行向量就是 A^T 的列向量, 因此矩阵 A 的行空间就是 A^T 的列空间, 即 $R(A) = C(A^T)$ 。

零空间, 即满足所有 $Ax=0$ 的向量 x 集合, 由线性无关和线性相关的知识可以得出, 当矩阵 A 的各列都是线性无关, 则 x 只有唯一解零向量, 当且仅当 A 的各列线性相关, x 才有非零解。根据矩阵乘法的原则, 当 A 是 $m \times n$ 矩阵, 所以 x 一定是 n 维。

左零空间, 和零空间相反, 零空间是满足所有 $Ax = 0$ 的向量 x 的集合, 左零空间是满足所有 $yA = 0$ 的向量 y 的集合, 根据矩阵的转置, 左零空间也就是满足所有 $A^T y = 0$ 的向量 y 的集合。根据矩阵乘法的原则, 当 A 是 $m \times n$ 矩阵, A^T 是 $n \times m$ 矩阵, 所以 y 一定是 m 维。

在文献中, 提到了矩阵的维度的概念, 综合上述对于四个子空间的描述, 我们可以得到以下四个子空间的关系:

- 1、矩阵 A 的列空间的维度数矩阵 A 的秩, 即 r 。
- 2、矩阵 A 的行空间的维度和列空间的维度数相等, 都是 r 。
- 3、矩阵 A 的零空间的维度数是 $n - r$, 列空间和零空间的维度数之和为 n 。
- 4、矩阵 A 的左零空间的维度数是 $m - r$, 行空间和左零空间的维度数之和为 m 。

最后, 文献根据正交的定义, 给出了四个基本子空间的正交关系:

- 1、列空间和左零空间正交。
- 2、行空间和零空间正交。

1.2.2 秩-零化度定理

秩-零化度定理: 定义域 V 的维数等于核空间 $\ker(T)$ 的维数与值域 $\text{ran}(T)$ 的维数之和, 即

$$\dim V = \dim \ker(T) + \text{rank} T$$

假设线性变换 $T: v \rightarrow w$ 由 $m \times n$ 阶矩阵 A 表示, 因此可得, $n = \dim v, m = \dim w$, 列空间 $C(A)$ 和零空间 $N(A)$ 分别表示线性变换 T 的值域 $\text{ran}(T)$ 和核空间 $\ker(T)$ 。

所以转换为证明: $n = \dim N(A) + \text{rank} A$ 。

证明过程如下:

$\because m \times n$ 矩阵 A 用 Gauss-Jordan 消元法可化简为分块矩阵 R 的形式:

$$R = \begin{bmatrix} I_r & F \\ 0 & 0 \end{bmatrix}$$

\therefore 矩阵 R 的秩为 r , F 是 $r \times (n - r)$ 阶矩阵。

\because Gauss-Jordan 消元法不改变矩阵 A 的秩和零空间

$\therefore \text{rank} A = \text{rank} R = r, N(A) = N(R)$

观察矩阵 R , 可得其 $n \times (n - r)$ 的零空间矩阵 P 如下:

$$P = \begin{bmatrix} -F \\ I_{n-r} \end{bmatrix}$$

验证:

$$RP = \begin{bmatrix} I_r & F \\ 0 & 0 \end{bmatrix} \begin{bmatrix} -F \\ I_{n-r} \end{bmatrix} = \begin{bmatrix} -F + F \\ 0 \end{bmatrix} = 0$$

易得: $\text{rank} P = n - r$

\therefore 列向量线性无关

\therefore 只需证 $\ker(R)$ 所有向量可由 P 的列向量线性表出, 即可得 $C(P) = N(R)$ 。

假设 $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$, 其中 x_1 是 r 维向量, x_2 是 $n - r$ 维向量, 使 $Rx = 0$

$$\therefore Rx = \begin{bmatrix} I_r & F \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0$$

$$\begin{aligned}
&\because x_1 = -Fx_2 \\
&\therefore x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} -Fx_2 \\ x_2 \end{bmatrix} = \begin{bmatrix} -F \\ I_{n-r} \end{bmatrix} x_2 = Px_2 \\
&\therefore C(P) = N(\tilde{R}) \\
&\text{即 } \dim N(A) = \dim NR = \text{rank} P = n-r \\
&\therefore n = \dim N(A) + \text{rank} A \\
&\therefore \text{秩-零化度定理成立}
\end{aligned}$$

1.3 矩阵求导

1.3.1 公式 1

$$\begin{aligned}
&\frac{\partial}{\partial X} \text{tr}(X^T AX) \\
&= d(\text{tr}(X^T AX)) \\
&= \text{tr}(d(X^T AX)) \\
&= \text{tr}(d(X^T)AX + X^T AdX) \\
&= \text{tr}((dX)^T AX + X^T AdX) \\
&= \text{tr}((AX)^T dX + X^T AdX) \\
&= \text{tr}(X^T A^T dX) + \text{tr}(X^T AdX) \\
&= \text{tr}(X^T A^T dX + X^T AdX)
\end{aligned}$$

$$\begin{aligned}
&\text{令 } f(X) = \text{tr}(X^T AX) \\
&\therefore \left(\frac{\partial f(X)}{\partial X}\right)^T = X^T(A^T + A) \\
&\therefore \frac{\partial f(X)}{\partial X} = (X^T(A^T + A))^T = (A + A^T)X \\
&\therefore \frac{\partial}{\partial X} \text{tr}(X^T AX) = (A^T + A)X
\end{aligned}$$

1.3.2 公式 2

$$\begin{aligned}
&\frac{\partial}{\partial X} \text{tr}(X^T AY) \\
&= d(\text{tr}(X^T AY)) \\
&= \text{tr}(d(X^T)AY) \\
&= \text{tr}((dX)^T AY) \\
&= \text{tr}(AY(dX)^T) \\
&= \text{tr}((AY)^T dX)
\end{aligned}$$

同 1.3.1 公式 1:

$$\therefore \frac{\partial}{\partial X} \text{tr}(X^T AY) = AY$$

1.3.3 公式 3

$$\begin{aligned}
 & \frac{\partial}{\partial Y} \text{tr}(X^T AY) \\
 &= d(\text{tr}(X^T AY)) \\
 &= \text{tr}(d(X^T AY)) \\
 &= \text{tr}(X^T A dY) \\
 &= \text{tr}((A^T X)^T dY)
 \end{aligned}$$

同 1.3.1 公式 1:

$$\therefore \frac{\partial}{\partial Y} \text{tr}(X^T AY) = A^T X$$

1.4 多元正态分布的等高面

1.4.1 证明概率密度等高面是椭球面

由题意: $X \sim \mathcal{N}(\mu, \Sigma) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right)$

因此对于 $f(x; \mu, \Sigma) = a$ 我们可以做以下变形:

$$\begin{aligned}
 & \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right) = a \\
 & \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right) = (2\pi)^{p/2} |\Sigma|^{1/2} a \\
 & (x - \mu)^T \Sigma^{-1}(x - \mu) = -2 \ln(2\pi)^{p/2} |\Sigma|^{1/2} a
 \end{aligned}$$

根据椭球的定义: 形如

$$\{x | (x - x_c)^T P^{-1}(x - x_c) \leq 1\}$$

的集合称为椭球。

因为 $a > 0$, 所以可以得出 $(x - \mu)^T \Sigma^{-1}(x - \mu) = -2 \ln(2\pi)^{p/2} |\Sigma|^{1/2} a$ 是椭球。

\therefore 概率密度等高面 $f(x; \mu, \Sigma) = a$ 是椭球面

1.4.2 求椭圆方程、长轴、短轴

由题意: $X \sim \mathcal{N}(\mu, \Sigma) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right)$

因此, 任给 $a > 0$, 我们可以取 $a_0 = (2\pi)^{p/2} |\Sigma|^{1/2}$

当 $0 < a < \frac{1}{a_0}$ 时, $f(x; \mu, \Sigma) = a \Leftrightarrow (x - \mu)^T \Sigma^{-1}(x - \mu) = b^2$, 其中 $b^2 = -2 \ln[a(2\pi)^{p/2} |\Sigma|^{1/2}] = -2 \ln[aa_0]$

$\therefore \Sigma > 0$ 且 $p = 2$

$\therefore \Sigma$ 的特征值记为 $\lambda_1 \geq \lambda_2 > 0$

$\therefore \lambda_i$ 对应的特征向量记为 l_1, l_2

$\therefore \Sigma^{-1}$ 的谱分解记为 $\Sigma^{-1} = \sum_{i=1}^2 \frac{1}{\lambda_i} l_i l_i'$

令 $y_i = (x - \mu)' l_i (i = 1, 2)$

\therefore 椭球面方程为:

$$\begin{aligned}
 (x - \mu)' \Sigma^{-1} (x - \mu) &= (x - \mu)' \sum_{i=1}^2 \frac{1}{\lambda_i} l_i l_i' (x - \mu) = b^2 \\
 &\Leftrightarrow \sum_{i=1}^2 \frac{1}{\lambda_i} y_i^2 = b^2 \\
 &\Leftrightarrow \frac{y_1^2}{\lambda_1 b^2} + \frac{y_2^2}{\lambda_2 b^2} = 1
 \end{aligned}$$

而当 $p=2$ 且 $\Sigma = \sigma^2 \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix}$ ($\rho > 0$) 时

我们可以得到: $|\Sigma| = \sigma^4 (1 - \rho^2)$

接下来计算 Σ 的特征值:

$$\begin{aligned}
 &|\Sigma - \lambda I_p| \\
 &= \begin{vmatrix} \sigma^2 - \lambda & \sigma^2 \rho \\ \sigma^2 \rho & \sigma^2 - \lambda \end{vmatrix} \\
 &= (\sigma^2 - \lambda)^2 - \sigma^4 \rho^2 \\
 &= (\sigma^2 - \lambda - \sigma^2 \rho) (\sigma^2 - \lambda + \sigma^2 \rho) \\
 &= 0
 \end{aligned}$$

可得 Σ 的特征值为 $\lambda_1 = \sigma^2(1 + \rho)$, $\lambda_2 = \sigma^2(1 - \rho)$

通过正交化和归一化得到对应的特征向量为:

$$l_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix} \quad l_2 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$$

由刚刚计算得到椭球面方程为:

$$\frac{y_1^2}{\lambda_1 b^2} + \frac{y_2^2}{\lambda_2 b^2} = 1$$

其中 $b^2 = -2 \ln [a(2\pi)|\Sigma|^{1/2}] = -2 \ln [2\pi\sigma^2\sqrt{1-\rho^2}a]$

\therefore 长轴为: $2b\sigma\sqrt{1+\rho}$, 短轴为: $2b\sigma\sqrt{1-\rho}$

1.5 多元正态分布的简单性质

1.5.1 计算 $\mathbb{E}[x] = \mu$

由题意得:

$$p(x | \mu, \Sigma) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right)$$

因此, 对于 $\mathbb{E}[x]$:

$$\begin{aligned}\mathbb{E}[x] &= \int_{\mathbb{R}^n} xp(x | \mu, \Sigma) dx \\ &= \int_{\mathbb{R}^n} \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right) x dx\end{aligned}$$

作变量代换, 令 $z = x - \mu$:

$$\begin{aligned}\mathbb{E}[x] &= \int_{\mathbb{R}^n} \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} z^T \Sigma^{-1} z \right) (z + \mu) dz \\ &= \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \left(\int_{\mathbb{R}^n} \exp \left(-\frac{1}{2} z^T \Sigma^{-1} z \right) z dz + \int_{\mathbb{R}^n} \exp \left(-\frac{1}{2} z^T \Sigma^{-1} z \right) \mu dz \right)\end{aligned}$$

由于 Σ 是正定对称矩阵

$\therefore \Sigma = Q^T \Lambda Q, \Sigma^{-1} = Q^T \Lambda^{-1} Q, t = Qz$

\therefore 第一项可以解出为奇函数 $\int_{\mathbb{R}^n} z dz$, 由奇函数积分性质可得其积分值为 0

而第二项可以看出其为正态分布概率密度函数在 R^n 中的积分, 因此可得最后的结果为:

$$\int_{\mathbb{R}^n} \mu dz = \mu$$

$$\therefore \mathbb{E}[x] = \int_{\mathbb{R}^n} xp(x | \mu, \Sigma) dx = \mu$$

1.5.2 计算 $\mathbb{E}[xx^T] = \Sigma + \mu\mu^T$

根据协方差矩阵的定义可得:

$$\text{Cov}(x, x^T) = \mathbb{E}[(x - \mu)(x^T - \mu^T)]$$

$$\text{Cov}(x, x^T) = D(X) = \Sigma$$

所以, 对于 $\text{Cov}(x, x^T)$ 进行展开:

$$\begin{aligned}\text{Cov}(x, x^T) &= \mathbb{E}[(x - \mu)(x^T - \mu^T)] \\ &= \mathbb{E}[xx^T] - \mathbb{E}[x\mu^T] - \mathbb{E}[\mu x^T] + \mathbb{E}[\mu\mu^T] \\ &= \mathbb{E}[xx^T] - \mu\mu^T - \mu\mu^T + \mu\mu^T \\ &= \mathbb{E}[xx^T] - \mu\mu^T\end{aligned}$$

结合 $\text{Cov}(x, x^T) = \Sigma$, 可得:

$$\Sigma = \mathbb{E}[xx^T] - \mu\mu^T$$

$$\therefore \mathbb{E}[xx^T] = \Sigma + \mu\mu^T$$

1.5.3 证明 $\mathbb{E}[x^T Ax] = \text{tr}(\Sigma A) + \mu^T A \mu$

由矩阵迹的性质: $x^T Ax = \text{tr}(x^T Ax) = \text{tr}(xx^T A)$

$\therefore \mathbb{E}[\text{tr}(x)] = \text{tr}(\mathbb{E}[x])$

\therefore 对 $\mathbb{E}[x^T Ax]$ 进行展开变形:

$$\begin{aligned}\mathbb{E}[x^T Ax] &= \mathbb{E}[\text{tr}(x^T Ax)] \\ &= \mathbb{E}[\text{tr}(xx^T A)] \\ &= \text{tr}(\mathbb{E}[xx^T A])\end{aligned}$$

$\therefore A$ 为对称矩阵

$\therefore \text{tr}(\mathbb{E}[xx^T A]) = \text{tr}(A\mathbb{E}[xx^T])$

由 1.5.2 可得: $\mathbb{E}[xx^T] = \Sigma + \mu\mu^T$

所以对 $\mathbb{E}[x^T Ax]$ 继续进行计算:

$$\begin{aligned}\mathbb{E}[x^T Ax] &= \text{tr}(A\mathbb{E}[xx^T]) \\ &= \text{tr}(A(\Sigma + \mu\mu^T)) \\ &= \text{tr}(A\Sigma) + \text{tr}(A\mu\mu^T) \\ &= \text{tr}(A\Sigma) + \text{tr}(\mu^T A \mu) \\ &= \text{tr}(A\Sigma) + \mu^T A \mu\end{aligned}$$

$\therefore \mathbb{E}[x^T Ax] = \text{tr}(\Sigma A) + \mu^T A \mu$

1.5.4 证明 $\mathbb{E}(X^T AX) = \sigma^2(p-1)$

由 1.5.3 可得:

$$\mathbb{E}[x^T Ax] = \text{tr}(\Sigma A) + \mu^T A \mu$$

当 $\mu = a\mathbf{1}_p$, $A = I_p - \frac{1}{p}\mathbf{1}_{p \times p}$, $\Sigma = \sigma^2 I_p$ 时, 对 $\mathbb{E}[x^T Ax]$ 进行展开:

$$\begin{aligned}\mathbb{E}[x^T Ax] &= \text{tr}(\Sigma A) + \mu^T A \mu \\ &= \text{tr}(\sigma^2 I_p (I_p - \frac{1}{p}\mathbf{1}_{p \times p})) + (a\mathbf{1}_p)^T (I_p - \frac{1}{p}\mathbf{1}_{p \times p})(a\mathbf{1}_p)\end{aligned}$$

由于 $\mathbf{1}_p$ 表示所有分量均为 1 的列向量, $\mathbf{1}_{p \times p}$ 表示所有元素均为 1 的矩阵
因此, 对上式中后一项继续计算:

$$\begin{aligned}
& (a\mathbf{1}_p)^T \left(I_p - \frac{1}{p} \mathbf{1}_{p \times p} \right) (a\mathbf{1}_p) \\
&= a\mathbf{1}_p^T \left(I_p - \frac{1}{p} \mathbf{1}_{p \times p} \right) (a\mathbf{1}_p) \\
&= (a\mathbf{1}_p^T - a \frac{1}{p} \times p \mathbf{1}_p^T) (a\mathbf{1}_p) \\
&= (a\mathbf{1}_p^T - a\mathbf{1}_p^T) (a\mathbf{1}_p) \\
&= 0
\end{aligned}$$

根据迹运算的性质，对前一项继续计算：

$$\begin{aligned}
& \text{tr}(\sigma^2 I_p (I_p - \frac{1}{p} \mathbf{1}_{p \times p})) \\
&= \text{tr}(\sigma^2 I_p - \frac{\sigma^2}{p} \mathbf{1}_{p \times p}) \\
&= \sigma^2 \text{tr}(I_p) - \sigma^2 \\
&= \sigma^2 p - \sigma^2 \\
&= \sigma^2 (p - 1)
\end{aligned}$$

$$\therefore \mathbb{E}(X^T A X) = \sigma^2 (p - 1)$$

1.6 多元正态分布的极大似然估计

1.6.1 推导 μ 和 Σ 的极大似然估计

题目给出了 p 元正态分布如下：

$$N_p(X \mid \mu, \Sigma) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (X - \mu)^T \Sigma^{-1} (X - \mu) \right)$$

所以对于数据 $\{X_i\}$ ，数据的极大似然函数为：

$$\begin{aligned}
\mathcal{L} &= \prod_{i=1}^n p(X_i \mid \theta) = \prod_{i=1}^n N_p(X \mid \mu, \Sigma) \\
&= \frac{1}{(2\pi)^{n^2/2} |\Sigma|^{n/2}} \exp \left(-\frac{1}{2} \sum_{i=1}^n (X_i - \mu)^T \Sigma^{-1} (X_i - \mu) \right)
\end{aligned}$$

两边取偏导可得：

$$\ln \mathcal{L} = \text{const} - \frac{n}{2} \ln \det \Sigma - \frac{1}{2} \sum_{i=1}^n (X_i - \mu)^T \Sigma^{-1} (X_i - \mu)$$

对 μ 求偏导可得：

$$\frac{\partial \ln \mathcal{L}}{\partial \mu} = -\Sigma^{-1} \sum_{i=1}^n (X_i - \mu)$$

令梯度 $\frac{\partial \ln \mathcal{L}}{\partial \mu} = 0$, 可得:

$$\mu = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

已知:

$$\frac{\partial \ln \det \Sigma}{\partial \Sigma} = \Sigma^{-1}$$

$$d\Sigma^{-1} = \Sigma^{-1} d\Sigma \Sigma^{-1}$$

对 Σ 求偏导得:

$$\frac{\partial \ln \mathcal{L}}{\partial \Sigma} = \Sigma^{-1} - \Sigma^{-1} \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}) (X_i - \bar{X})^T \Sigma^{-1}$$

令梯度 $\frac{\partial \ln \mathcal{L}}{\partial \Sigma} = 0$, 可得:

$$\Sigma = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}) (X_i - \bar{X})^T = A$$

1.6.2 证明 $\bar{X} \sim N(\mu, \frac{1}{n}\Sigma)$

要证明 $\bar{X} \sim N(\mu, \frac{1}{n}\Sigma)$, 即证明 \bar{X} 服从正态分布, 且 μ 和 $\frac{1}{n}\Sigma$ 分别为该正态分布的期望和方差

首先由于正态分布的线性性, 且 $X \sim N(\mu, \Sigma)$, $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_{(i)}$, 则易得 \bar{X} 依然服从正态分布

接下来证明 μ 和 $\frac{1}{n}\Sigma$ 分别为该正态分布的期望和方差:

$$\begin{aligned} \mathbb{E}(\bar{X}) &= \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) \\ &= \frac{1}{n} \sum_{i=1}^n \mu \\ &= \mu \end{aligned}$$

$$\therefore \bar{X} \sim N\left(\mu, \frac{1}{n}\Sigma\right)$$

$$\begin{aligned} \mathbb{D}(\bar{X}) &= \mathbb{D}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n \mathbb{D}(X_i) \\ &= \frac{1}{n^2} \sum_{i=1}^n \Sigma \\ &= \frac{1}{n} \Sigma \end{aligned}$$

1.6.3 证明 \bar{X} 是 μ 的无偏估计

根据题目中给出的无偏估计定义：当样本满足 $\mathbb{E}(\hat{\theta}) = \theta$ ，我们就称 $\hat{\theta}$ 是 θ 的无偏估计
根据 1.6.2 中给出的：

$$\begin{aligned}\mathbb{E}(\bar{X}) &= \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) \\ &= \frac{1}{n} \sum_{i=1}^n \mu \\ &= \mu\end{aligned}$$

$\therefore \bar{X}$ 是 μ 的无偏估计

1.7 范数的严格凸性

证明. (\Rightarrow):

已知 $\|x + y\| = \|x\| + \|y\| (\forall x \neq \theta, y \neq \theta)$

要证明 $x = cy$ ，可转化为证明 $\frac{x}{\|x\|} = \frac{y}{\|y\|}$

\therefore 单位向量 $\frac{x}{\|x\|} = \frac{y}{\|y\|} = 1$ 且 $\|x\| + \|y\| > 0$

$\therefore \|x\| + \|y\| \neq 0$ ，且 $\frac{\|x\|}{\|x+y\|} + \frac{\|y\|}{\|x+y\|} = 1$

假设 $\frac{x}{\|x\|} \neq \frac{y}{\|y\|}$

由范数的严格凸性，可得：

$$\left(\frac{\|x\|}{\|x+y\|}\right) \left(\frac{\|x\|}{\|x\|}\right) + \left(\frac{\|y\|}{\|x+y\|}\right) \left(\frac{\|y\|}{\|y\|}\right) < 1$$

即 $\frac{\|x+y\|}{\|x+y\|} < 1$ ，与已知条件矛盾

$\therefore \frac{x}{\|x\|} = \frac{y}{\|y\|}$ ，即 $x = \left(\frac{\|x\|}{\|y\|}\right)y$

$\therefore x = cy$

证明. (\Leftarrow):

已知 $x = cy$ ，要证 $\|x + y\| = \|x\| + \|y\| (\forall x \neq \theta, y \neq \theta)$ ，即证范数是严格凸的

设 $x \neq y$ 且 $\|x\| = \|y\| = 1$ ， $\alpha, \beta \in (0, 1)$ 且 $\alpha + \beta = 1$

\therefore 根据不等式性质可得：

$$\|\alpha x + \beta y\| \leq \|\alpha x\| + \|\beta y\| = \alpha\|x\| + \beta\|y\| = \alpha + \beta = 1$$

设 $\|\alpha x + \beta y\| = 1$

$\therefore x = cy$

$\therefore \alpha x = c(\beta y)$

$\therefore \|\alpha x\| = \|c(\beta y)\|$

$\therefore \|x\| = \|y\| = 1$

$\therefore \alpha = c\beta$
 $\therefore x = y$, 与 $x \neq y$ 矛盾
 $\therefore \|\alpha x + \beta y\| < 1$, 即范数是严格凸的。

1.8 证明：凸函数的局部极小值必然是全空间的极小值

设 x_1, x_2 都是局部极小点, 并且 $x_1 \neq x_2$
 假设 $\varphi(x_1) > \varphi(x_2)$
 \therefore 不等式 $\varphi(\lambda x + (1 - \lambda)y) \leq \lambda\varphi(x) + (1 - \lambda)\varphi(y) (\forall 0 \leq \lambda \leq 1)$ 成立
 $\therefore \varphi(x_1) > (1 - \lambda)\varphi(x_1) + (\lambda)\varphi(x_2) \geq \varphi(\lambda x_1 + (1 - \lambda)x_2)$
 令 $y_\lambda = (1 - \lambda)x_1 + \lambda x_2$
 当 $\lambda \rightarrow 0$ 的时候, $\lim_{\lambda \rightarrow 0} y_\lambda = x_1$
 $\therefore \varphi(x_1) > \varphi(y_\lambda)$, 与 x_1 为局部极小点矛盾
 $\therefore \varphi(x_1) \geq \varphi(x_2)$
 同理可得: $\varphi(x_1) \leq \varphi(x_2)$
 $\therefore \varphi(x_1) = \varphi(x_2)$
 \therefore 凸函数的局部极小值必然是全空间的极小值

1.9 投影的最优性条件

1.9.1 计算数据 x_i 在 L 的投影所对应的点 \tilde{x}

由题意得: 定义 $\tilde{x}_i = \arg \min_{y \in L} \|x_i - y\|$ 为 x 在 L 上的投影, 以 w 为方向向量, 过点 \bar{x} 的
 直线为 $L = \{y \in \mathbb{R}^n \mid y = \bar{x} + tw, t \in \mathbb{R}\}$
 因此要求 x , 可转化为求 $\min_t \|x_i - \bar{x} - tw\|_2$

$$\begin{aligned}
 & \|x_i - \bar{x} - tw\|_2^2 \\
 &= t^2 - 2tw^T(x_i - \bar{x}) + \|x_i - \bar{x}\|_2^2 \\
 &= (t - w^T(x_i - \bar{x}))^2 + \text{constant}
 \end{aligned}$$

\therefore 最优解 $t^* = w^T(x_i - \bar{x})$
 $\therefore w$ 不是单位向量
 $\therefore t^* = \frac{w^T(x_i - \bar{x})}{w^T w}$
 $\therefore x_i$ 在 L 上的投影所对应的点:

$$\tilde{x} = \bar{x} + t^*w = \bar{x} + \frac{w^T(x_i - \bar{x})}{w^T w} w$$

1.9.2 对于目标函数 $\min_w J(w)$ 求最优点满足的最优性条件

由 1.9.1 可得:

$$\tilde{x} = \bar{x} + t^*w = \bar{x} + \frac{w^T(x_i - \bar{x})}{w^T w} w$$

$\therefore \|w\| = 1$, 即 w 是单位向量

$$\therefore \min_{\mathbf{w}} J(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2 = \frac{1}{N} \sum_{i=1}^N \|\mathbf{x}_i - \bar{\mathbf{x}} + \mathbf{w}^T (\mathbf{x}_i - \bar{\mathbf{x}}) \mathbf{w}\|$$

令 $\mathbf{y}_i = \mathbf{x}_i - \bar{\mathbf{x}}$

$$\text{即 } J(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N \|\mathbf{y}_i - \mathbf{w}^T \mathbf{y}_i \mathbf{w}\|$$

所以由范数的计算性质：

$$\begin{aligned} J(\mathbf{w}) &= \frac{1}{N} \sum_{i=1}^N \|\mathbf{y}_i - \mathbf{w}^T \mathbf{y}_i \mathbf{w}\| \\ &= \frac{1}{N} \sum_{i=1}^N (\mathbf{y}_i - \mathbf{w}^T \mathbf{y}_i \mathbf{w})^T (\mathbf{y}_i - \mathbf{w}^T \mathbf{y}_i \mathbf{w}) \\ &= \frac{1}{N} \sum_{i=1}^N (\mathbf{y}_i^T \mathbf{y}_i - \mathbf{y}_i^T \mathbf{w}^T \mathbf{y}_i \mathbf{w} - \mathbf{w}^T \mathbf{y}_i^T \mathbf{w} \mathbf{y}_i + \mathbf{w}^T \mathbf{y}_i^T \mathbf{y}_i \mathbf{w}) \end{aligned}$$

$$\because \|\mathbf{w}\| = 1$$

$$\therefore \mathbf{y}_i^T \mathbf{w}^T \mathbf{y}_i \mathbf{w} = \mathbf{w}^T \mathbf{y}_i^T \mathbf{w} \mathbf{y}_i = \mathbf{w}^T \mathbf{y}_i^T \mathbf{y}_i \mathbf{w}$$

因此，对 $J(\mathbf{w})$ 进行进一步的化简：

$$\begin{aligned} J(\mathbf{w}) &= \frac{1}{N} \sum_{i=1}^N (\mathbf{y}_i^T \mathbf{y}_i - \mathbf{w}^T \mathbf{y}_i^T \mathbf{y}_i \mathbf{w}) \\ &= \frac{1}{N} \sum_{i=1}^N \mathbf{y}_i^T \mathbf{y}_i - \mathbf{w}^T \left(\frac{1}{N} \sum_{i=1}^N \mathbf{y}_i^T \mathbf{y}_i \right) \mathbf{w} \end{aligned}$$

记 $\frac{1}{N} \sum_{i=1}^N \mathbf{y}_i^T \mathbf{y}_i$ 为矩阵 \mathbf{Y}

由瑞利商的定义和性质：

$$\lambda_{\min}(\mathbf{A}) = \min_{\mathbf{x}^T \mathbf{x} = 1} \mathbf{x}^T \mathbf{A} \mathbf{x} = \min_{\mathbf{x} \neq 0} \frac{\mathbf{x}^T \mathbf{A} \mathbf{x}}{\mathbf{x}^T \mathbf{x}}$$

可得该最优点的最优性条件为矩阵 \mathbf{Y} 的最小特征值

1.9.3 对于目标函数 $\max_{\mathbf{w}} J(\mathbf{w})$ 求最优点满足的最优性条件

由 1.9.1 可得：

$$\tilde{\mathbf{x}} = \bar{\mathbf{x}} + t^* \mathbf{w} = \bar{\mathbf{x}} + \frac{\mathbf{w}^T (\mathbf{x}_i - \bar{\mathbf{x}}) \mathbf{w}}{\mathbf{w}^T \mathbf{w}}$$

$\because \|\mathbf{w}\| = 1$ ，即 \mathbf{w} 是单位向量

$$\therefore \mathbf{w}^T \mathbf{w} = 1$$

已知目标函数：

$$\max_{\mathbf{w}} K(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (t_i^*)^2$$

对目标函数进行展开并化简：

$$\begin{aligned}
\max_{\mathbf{w}} K(\mathbf{w}) &= \frac{1}{N} \sum_{i=1}^N \left(\frac{\mathbf{w}^T (\mathbf{x}_i - \bar{\mathbf{x}}) \mathbf{w}}{\mathbf{w}^T \mathbf{w}} \right)^2 \\
&= \frac{1}{N} \sum_{i=1}^N (\mathbf{w}^T (\mathbf{x}_i - \bar{\mathbf{x}}) \mathbf{w})^2 \\
&= \frac{1}{N} \sum_{i=1}^N (\mathbf{w}^T (\mathbf{x}_i - \bar{\mathbf{x}}) \mathbf{w})^T (\mathbf{w}^T (\mathbf{x}_i - \bar{\mathbf{x}}) \mathbf{w}) \\
&= \frac{1}{N} \sum_{i=1}^N \mathbf{w}^T (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w} \\
&= \mathbf{w}^T \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w}
\end{aligned}$$

记 $\frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^T$ 为矩阵 \mathbf{X}
 由瑞利商的定义和性质:

$$\lambda_{\max}(\mathbf{A}) = \max_{\mathbf{x}^T \mathbf{x} = 1} \mathbf{x}^T \mathbf{A} \mathbf{x} = \max_{\mathbf{x} \neq 0} \frac{\mathbf{x}^T \mathbf{A} \mathbf{x}}{\mathbf{x}^T \mathbf{x}}$$

可得该最优点的最优性条件为矩阵 \mathbf{X} 的最大特征值

1.10 KL 散度的简单介绍

1.10.1 验证对称性

已知:

$$\begin{aligned}
D_{\text{KL}}(p||q) &= \int_{\mathbb{R}^n} p(x)(\log p(x) - \log q(x))dx \\
D_{\text{KL}}(q||p) &= \int_{\mathbb{R}^n} q(x)(\log q(x) - \log p(x))dx
\end{aligned}$$

所以:

$$\begin{aligned}
&D_{\text{KL}}(p||q) - D_{\text{KL}}(q||p) \\
&= \int_{\mathbb{R}^n} [p(x)(\log p(x) - \log q(x)) - q(x)(\log q(x) - \log p(x))] dx \\
&= \int_{\mathbb{R}^n} [(p(x) + q(x)) (\log p(x) - \log q(x))] dx
\end{aligned}$$

$\therefore \log p(x) - \log q(x)$ 和 $p(x) + q(x)$ 都不一定为 0
 $\therefore D_{\text{KL}}(p||q)$ 和 $D_{\text{KL}}(q||p)$ 在 $\forall p, q$ 的条件下不一定相等
 \therefore KL 散度不一定满足对称性。

1.10.2 验证非负性

根据对数的运算性质：

$$D_{\text{KL}}(p||q) = \int_{\mathbb{R}^n} p(x)(\log p(x) - \log q(x))dx = \int_{\mathbb{R}^n} p(x)(-\ln \frac{q(x)}{p(x)})dx$$

令 $f(x) = -\ln x$ ，令 $g(x) = \frac{q(x)}{p(x)}$

由 $f(x)$ 为凸函数，应用 Jensen 不等式：

$$\int_{\mathbb{R}^n} p(x)f(g(x))dx \geq f\left(\int_{\mathbb{R}^n} p(x)\frac{q(x)}{p(x)}dx\right) = f\left(\int_{\mathbb{R}^n} q(x)dx\right)$$

由 q 为概率分布可得： $\int_{\mathbb{R}^n} q(x)dx = 1$

$\therefore \int_{\mathbb{R}^n} p(x)f(g(x))dx \geq f(1) = -\ln 1 = 0$ ，即 $D_{\text{KL}}(p||q) \geq 0$

\therefore KL 散度有非负性。

2 编程题

2.1 Gauss-Jordan 消元法

带帐号名的 AC 截图：



Figure 1: 带帐号名的 AC 截图.

源代码：


```
#include<stdio>
#include<cmath>

const double EPS=1E-8;
double B[100][100];
int n;

int main(){
    scanf("%d",&n);
    for (int i=0;i<n;i++)
    {
        for (int j=0;j<n;j++)
            scanf("%lf",&B[i][j]);
        scanf("%lf",&B[i][n]);
    }
    for (int i=0;i<n;i++)
    {
        int pivot=i;
        for (int j=i;j<n;j++)
            if (fabs(B[j][i]-B[pivot][i])<=EPS)//寻找主元
                pivot=j;
        for (int j=0;j<n;j++)//将主元所在行换到第一行
        {
            double t=B[i][j];
            B[i][j]=B[pivot][j];
            B[pivot][j]=t;
        }
        if (fabs(B[i][i])<=EPS) {//如果该位置系数等于零, 则0x=a, 一定无解
            printf("No Solution\n");
            return 0;
        }
    }
}
```

Figure 2: 源代码 1

```
for (int j=i+1;j<n;j++) //将主元所在行的所有元素全部除以主元的值
    B[i][j]/=B[i][i];
for (int j=0;j<n;j++)//对于其他行进行化简
    if (i!=j)
        for (int k=i+1;k<n;k++)
            B[j][k]-=B[j][i]*B[i][k];
for (int i=0;i<n;i++)
    printf("%.2lf\n",B[i][n]);
return 0;
}
```

Figure 3: 源代码 2

2.2 凸包的简单应用

2.2.1 伪代码

Algorithm 1: Magic Rabbit

Data: 三瓶药水 x, y, z 中材料 a 含量 a_1, a_2, a_3 , 材料 b 含量 b_1, b_2, b_3 , 合成药水中材料 a 含量 m , 材料 b 含量 n

Result: 是否能配出含有 mg 材料 a , ng 材料 b 的药水

1 首先根据题意, 我们可以得出以下两个方程:

$$a_1x + a_2y + a_3(1 - x - y) = m = (x + y + 1 - x - y)m$$

$$b_1x + b_2y + b_3(1 - x - y) = n = (x + y + 1 - x - y)n$$

2 经过化简可得:

$$3 (a_1 - m)x + (a_2 - m)y + (a_3 - m)(1 - x - y) = 0$$

$$(b_1 - n)x + (b_2 - n)y + (b_3 - n)(1 - x - y) = 0$$

4 根据式子的形式, 我们可以借助空间几何内积点乘和外积叉乘的定义进行解题:

5 设 $\mathbf{a}, \mathbf{b}, \mathbf{q}$ 向量, 其中:

$$6 \mathbf{a} = (a_1 - m, a_2 - m, a_3 - m)^T \mathbf{b} = (b_1 - n, b_2 - n, b_3 - n)^T \mathbf{q} = (x, y, 1 - x - y)^T$$

7 因此, 我们将两个式子看成: $\langle \mathbf{a}, \mathbf{q} \rangle = \mathbf{a}^T \mathbf{q} = 0$ $\langle \mathbf{b}, \mathbf{q} \rangle = \mathbf{b}^T \mathbf{q} = 0$

8 我们可以得出向量 \mathbf{a} 和向量 \mathbf{q} 正交, 向量 \mathbf{b} 和向量 \mathbf{q} 正交, 所以我们可以得到向量 \mathbf{q} 垂直于向量 \mathbf{a} 和向量 \mathbf{b} 形成的平面。

9 那么根据外积的定义, 我们可以得到:

$$\mathbf{a} \times \mathbf{b} = \begin{bmatrix} [3]x & y & 1 - x - y \\ a_1 - m & a_2 - m & a_3 - m \\ b_1 - n & b_2 - n & b_3 - n \end{bmatrix} = ((a_2 - m)(b_3 - n) - (b_2 - n)(a_3 - m))x - ((a_1 - m)(b_3 - n) - (b_1 - n)(a_3 - m))y + ((a_1 - m)(b_2 - n) - (b_1 - n)(a_2 - m))(1 - x - y)$$

10 为了方便表示:

$$11 \text{ num1} \leftarrow (a_2 - m)(b_3 - n) - (b_2 - n)(a_3 - m)$$

$$\text{num2} \leftarrow -(a_1 - m)(b_3 - n) + (b_1 - n)(a_3 - m)$$

$$\text{num3} \leftarrow (a_1 - m)(b_2 - n) - (b_1 - n)(a_2 - m)$$

12 为了使药水含量有意义, 我们必须保证 $\text{num1}, \text{num2}, \text{num3}$ 都 >0 或者都 <0 。

13 **for** $i \leftarrow 1$ **to** count **do**

$$14 \quad \text{num1} \leftarrow (a_2 - m)(b_3 - n) - (b_2 - n)(a_3 - m);$$

$$15 \quad \text{num2} \leftarrow -(a_1 - m)(b_3 - n) + (b_1 - n)(a_3 - m);$$

$$16 \quad \text{num3} \leftarrow (a_1 - m)(b_2 - n) - (b_1 - n)(a_2 - m);$$

17 **if** $\text{num1} \geq 0$ **and** $\text{num2} \geq 0$ **and** $\text{num3} \geq 0$ **then**

18 | YES;

19 **else if** $\text{num1} \leq 0$ **and** $\text{num2} \leq 0$ **and** $\text{num3} \leq 0$ **then**

20 | YES;

21 **else** NO;

22 **end**

2.2.2 C++ 源代码

```
#include <iostream>
using namespace std;
bool func(int a[4], int b[4], int m, int n)
{
    int num1 = (a[2] - m) * (b[3] - n) - (a[3] - m) * (b[2] - n);
    int num2 = -(a[1] - m) * (b[3] - n) + (a[3] - m) * (b[1] - n);
    int num3 = (a[1] - m) * (b[2] - n) - (a[2] - m) * (b[1] - n);
    if (num1 >= 0 && num2 >= 0 && num3 >= 0)
        return true;
    if (num1 <= 0 && num2 <= 0 && num3 <= 0)
        return true;
    return false;
}

int main()
{
    int a[4], b[4];

    for (int i = 1; i <= 3; i++)
        cin >> a[i] >> b[i];

    int m, n, count;
    cin >> count;
```

Figure 4: 源代码 1

```
int main()
{
    int a[4], b[4];

    for (int i = 1; i <= 3; i++)
        cin >> a[i] >> b[i];

    int m, n, count;
    cin >> count;

    for (int i = 0; i < count; i++)
    {
        cin >> m >> n;

        if (func(a, b, m, n))
            cout << "YES" << endl;
        else
            cout << "NO" << endl;
    }

    return 0;
}
```

Figure 5: 源代码 2