

最优化第四次作业

162050127 颜劭铭

2022 年 5 月 22 日

1 基础题

1.1 令 A 是一个 $n \times n$ 的实对称矩阵, 其特征值为 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$, λ_i 对应的特征向量为 u_i . A 的特征分解为 $A = U^T \Lambda U$, 其中 U 是正交矩阵, U 的第 i 列为 u_i , $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ 为对角阵.

1.1.1 对于任意 $x \neq 0$,

$$R(x, A) = \frac{x^T A x}{x^T x}$$

称为 Rayleigh 商. 证明对于任意的 $c \neq 0$, 都有 $R(cx, A) = R(x, A)$.

已知对于任意 $x \neq 0$, 有瑞利商:

$$R(x, A) = \frac{x^T A x}{x^T x}$$

又因为 $c \neq 0$, 所以:

$$R(cx, A) = \frac{(cx)^T A (cx)}{(cx)^T (cx)} = \frac{cx^T A cx}{cx^T cx} = \frac{c^2 x^T A x}{c^2 x^T x} = \frac{x^T A x}{x^T x} = R(x, A)$$

所以得证.

1.1.2 证明

$$\max_x \frac{x^T A x}{x^T x} = \max_{\|x\|=1} x^T A x$$

设 $R(x, A)$ 在 x^* 处取到最大值, 即:

$$R(x^*, A) = \max_x \frac{x^T A x}{x^T x}$$

又因为要证

$$\max_x \frac{x^T A x}{x^T x} = \max_{\|x\|=1} x^T A x$$

因此可将 x^* 单位化:

$$\exists c \neq 0, \text{使} \|cx^*\| = 1$$

由 1.1.1 可得:

$$R(x^*, A) = R(cx^*, A) = \frac{(cx^*)^T A (cx^*)}{(cx^*)^T (cx^*)} = \frac{c^2 x^{*T} A x^*}{\|cx^*\|^2} = c^2 x^{*T} A x^* = \max_{\|x\|=1} x^T A x$$

得证.

1.1.3 证明: 对于任一单位向量 x , 都可以表示成 $x = \sum_{i=1}^n w_i u_i$, 其中 u_i 为特征向量, w_i 满足 $\|w\|^2 = \sum_{i=1}^n w_i^2 = 1$.

转化为证明 $x = \sum_{i=1}^n w_i \mu_i$ 和当 $\|w\| = 1$ 时, x 为单位向量.

由题意可得: μ_i 为 A 的特征向量, 因此:

$$u_i^T u_j = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$

且 n 个特征向量是线性无关的, 为一组基, 因此可得: $\forall x \in R^n$ 可由这 n 个特征向量线性表出, 即 $x = \sum_{i=1}^n w_i \mu_i$.

接下来证明当 $\|w\| = 1$ 时, x 为单位向量.

$$\begin{aligned} \|x\|^2 &= x^T x = (w_1 \mu_1 + w_2 \mu_2 + \cdots + w_n \mu_n)^T (w_1 \mu_1 + w_2 \mu_2 + \cdots + w_n \mu_n) \\ &= \sum_{i=1}^n w_i^2 \mu_i^T \mu_i \\ &= \|w\|^2 = 1 \end{aligned}$$

因此得证.

1.1.4 证明

$$\max_{\|x\|=1} x^T A x = \lambda_1$$

并分析取到极大值时, 最优的 x 是多少? (提示, 利用 c 的结论, 将 x 写成特征向量的线性组合).

1.1.5 证明

$$\min_{\|x\|=1} x^T A x = \lambda_n$$

并分析取到极小值时, 最优的 x 是多少? (提示, 利用 c 的结论, 将 x 写成特征向量的线性组合).

1.1.4 和 1.1.5 因为证明思路相同, 所以合起来证明.

由于 A 为实对称矩阵, 其特征值为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$, 可以对其进行特征分解为 $A = U^T \Lambda U$, 其中 U 是正交矩阵, U 的第 i 列为 u_i , $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ 为对角阵.

因此瑞利商可以进行如下转化:

$$R(x, A) = \frac{x^T A x}{x^T x} = \frac{x^T U \Lambda U^T x}{x^T U U^T x}$$

令 $y = U^T x$, 继续进行变换:

$$R(x, A) = \frac{y^T \Lambda y}{y^T y} = \frac{\sum_{i=1}^n \lambda_i y_i^2}{\sum_{i=1}^n y_i^2}$$

由特征值大小的关系显然有:

$$\lambda_n \sum_{i=1}^n y_i^2 \leq \sum_{i=1}^n \lambda_i y_i^2 \leq \lambda_1 \sum_{i=1}^n y_i^2$$

于是有:

$$\begin{aligned} \frac{\lambda_n \sum_{i=1}^n y_i^2}{\sum_{i=1}^n y_i^2} &\leq \frac{\sum_{i=1}^n \lambda_i y_i^2}{\sum_{i=1}^n y_i^2} \leq \frac{\lambda_1 \sum_{i=1}^n y_i^2}{\sum_{i=1}^n y_i^2} \\ \Rightarrow \lambda_n &\leq R(x, A) \leq \lambda_1 \end{aligned}$$

又由 1.1.2 的结论可得:

$$\min_{\|x\|=1} x^T A x = \lambda_n \quad \max_{\|x\|=1} x^T A x = \lambda_1$$

由 1.1.3 可得:

$$\begin{aligned} x^T A x &= \left(\sum_{i=1}^n w_i u_i \right)^T A \left(\sum_{i=1}^n w_i u_i \right) \\ &= \left(\sum_{i=1}^n w_i u_i \right)^T \left(\sum_{i=1}^n w_i A u_i \right) \\ &\text{由于 } A u_i = \lambda_i u_i \\ &= \left(\sum_{i=1}^n w_i u_i \right)^T \left(\sum_{i=1}^n w_i \lambda_i u_i \right) \\ &= \sum_{i=1}^n \lambda_i w_i^2 u_i^T u_i \\ &= \sum_{i=1}^n \lambda_i w_i^2 \end{aligned}$$

因此当取得极大值时, $w = [1, 0, \dots, 0]^T$.

取得极小值时, $w = [0, 0, \dots, 1]^T$.

1.2 考虑约束优化问题

$$\max f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T Q \mathbf{x}, \quad \text{s.t. } \|\mathbf{x}\| = 1.$$

使用固定步长的投影梯度法求解上述问题, 迭代公式为

$$\mathbf{x}_{k+1} = \Pi_{y \in D} (\mathbf{x}_k + \alpha \nabla f(\mathbf{x}_k))$$

其中, $\alpha > 0$, $\Pi(\mathbf{x}) = \arg \min_{y \in D} \|\mathbf{x} - y\|$, D 为约束集 $D = \{\mathbf{x} \mid \|\mathbf{x}\| = 1\}$.

1.2.1 对于 $\mathbf{x} \neq 0$, 求出上面投影函数的显示表达式.

由于 $\Pi(\mathbf{x}) = \arg \min_{y \in D} \|\mathbf{x} - y\|$, 因此投影函数 $\mathbf{x}_{k+1} = \Pi_{y \in D} (\mathbf{x}_k + \alpha \nabla f(\mathbf{x}_k))$ 的显示表达式为:

$$\Pi_{y \in D} (\mathbf{x}_k + \alpha \nabla f(\mathbf{x}_k)) = \arg \min_{y \in D} \|\mathbf{x}_k + \alpha \nabla f(\mathbf{x}_k) - y\|$$

由于 $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T Q \mathbf{x}$, 因此 $\nabla f(x_k) = Qx_k$.

因此可以构造拉格朗日函数 $L(y, \lambda) = \|\mathbf{x}_k + \alpha \nabla f(\mathbf{x}_k) - y\|^2 + \lambda(1 - y^T y)$

对上述式子求偏导可得:

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial y} = 2(x_k + \alpha Qx_k - y) - 2\lambda y \\ \frac{\partial \mathcal{L}}{\partial \lambda} = 1 - y^T y \end{cases}$$

令偏导为 0, 可以解得:

$$y = \frac{x_k(I_n + \alpha Q)}{1 - \lambda}$$

求二阶偏导可得:

$$\frac{\partial^2 L}{\partial y^2} = 2(1 - \lambda)$$

且由刚刚的计算结果可得:

$$(1 - \lambda)^2 = \frac{\|x_k(I_n + \alpha Q)\|^2}{\|y\|^2} = \|x_k(I_n + \alpha Q)\|^2$$

所以可得, $\frac{\partial^2 L}{\partial y^2} = 2\|x_k(I_n + \alpha Q)\|$

因为 $Q = \text{diag}(1, 2)$ 且 $\|x_k\| = 1$

所以 $\frac{\partial^2 L}{\partial y^2} > 0$, 所以该极值点为极小值点, 且

$$x_{k+1} = y = \frac{x_k(I_n + \alpha Q)}{\|x_k(I_n + \alpha Q)\|}$$

1.2.2 令 $Q = \text{diag}(1, 2)$. 写出上面问题的最优性条件.

已知优化问题:

$$\begin{cases} \max f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T Q \mathbf{x} \\ \text{s.t. } \|\mathbf{x}\| = 1 \end{cases}$$

因此可以构造拉格朗日函数, $L(x, \lambda) = \frac{1}{2}\mathbf{x}^T Q \mathbf{x} + \lambda(1 - \|\mathbf{x}\|) = \frac{1}{2}\mathbf{x}^T Q \mathbf{x} + \lambda(1 - \sqrt{x^T x})$.

所以 KKT 条件为:

$$\begin{cases} \nabla_x L(x, \lambda) = Qx - \lambda \frac{x}{\|x\|} = 0 \\ \nabla_\lambda L(x, \lambda) = \|x\| - 1 = 0 \end{cases}$$

所以结合上述两个式子可得： x^* 是对应于特征值 λ^* 的特征向量。

由因为 $Q = \text{diag}(1, 2)$ ，所以 $\lambda_1 = 1$ 对应的特征向量为 $[0, 1]$ ， $\lambda_2 = 2$ 对应的特征向量为 $[1, 0]$ 。

1.2.3 令 $Q = \text{diag}(1, 2)$ ，判断临界点类型，确定最优解。

对于正定矩阵 $Q = U\Lambda U^T$ ， $UU^T = I$ ， Λ 为特征值的对角矩阵，且 $\lambda_1 = 1, \lambda_2 = 2$ ，则 1.2.2 的拉格朗日函数的 Hessian 矩阵可写为：

$$\nabla_x^2 L(x, \lambda) = Q - \lambda I$$

对于 $\lambda_1 = 1$ ， $\nabla_x^2 L(x, \lambda) = Q - \lambda_1 I = 0$ ，代入原式 $f(x)$ 可算出结果为 2。

对于 $\lambda_2 = 2$ ， $\nabla_x^2 L(x, \lambda) = Q - \lambda_2 I = 0$ ，代入原式 $f(x)$ 可算出结果为 1。

因此特征值 λ_1 对应的特征向量 $[0, 1]$ 为最优解，特征值 λ_2 对应的特征向量 $[1, 0]$ 是鞍点。

1.3 考虑优化问题

$$\min_{(x, y) \in \mathbb{R}^2} f(x) = (x - 1)^2 + y - 2$$

$$\text{s.t. } h(x) = y - x - 1 = 0$$

$$g(x) = x + y - 2 \leq 0$$

计算满足 KKT 条件的点，并利用二阶条件验证上述点是否是局部极小值点。

已知优化问题：

$$\begin{cases} \min_{(x, y) \in \mathbb{R}^2} f(x) = (x - 1)^2 + y - 2 \\ \text{s.t. } h(x) = y - x - 1 = 0 \\ g(x) = x + y - 2 \leq 0 \end{cases}$$

因此可以构造拉格朗日函数： $L(x, y, \lambda_1, \lambda_2) = f(x) + \lambda_1 h(x) + \lambda_2 g(x) = (x - 1)^2 + y - 2 + \lambda_1(y - x - 1) + \lambda_2(x + y - 2)$ 。

解得 KKT 条件为：

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial x} = 2(x-1) - \lambda_1 + \lambda_2 = 0 \\ \frac{\partial \mathcal{L}}{\partial y} = 1 + \lambda_1 + \lambda_2 = 0 \\ y - x - 1 = 0 \\ x + y - 2 = 0 \\ \lambda_2(y + x - 2) = 0 \\ \lambda_2 \geq 0 \end{cases}$$

解得：

$$\begin{cases} x^* = \frac{1}{2} \\ y^* = \frac{3}{2} \\ \lambda_1^* = -1 \\ \lambda_2^* = 0 \end{cases}$$

对 $f(x)$ 进行变换：

$$\begin{aligned} f(x) &= x^2 - 2x + 1 + y - 2 = x^2 - 2x + y - 1 \\ &= \frac{1}{2} \begin{bmatrix} x & y \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} + \begin{bmatrix} -2 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} - 1 \\ \text{令 } t &= \begin{bmatrix} x \\ y \end{bmatrix} \\ &= \frac{1}{2} t^T Q t + b^T t + c \end{aligned}$$

因此同理可以对约束函数进行变换得：

$$h(x) = \begin{bmatrix} -1 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} - 1 \quad g(x) = \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} - 2$$

因此再次构造拉格朗日函数：

$$L(t, \lambda_1, \lambda_2) = \frac{1}{2} t^T Q t + b^T t + c + \lambda_1 h(X) + \lambda_2 g(x)$$

求偏导得：

$$\begin{aligned}\frac{\partial L}{\partial t} &= \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix} t + \begin{bmatrix} -2 & 1 \end{bmatrix} + \lambda_1 \begin{bmatrix} -1 \\ 1 \end{bmatrix} + \lambda_2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ \frac{\partial^2 L}{\partial t^2} &= \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}\end{aligned}$$

由于 $\frac{\partial^2 L}{\partial t^2} \succcurlyeq 0$, 所以 $(\frac{1}{2}, \frac{3}{2})$ 为极小点.

1.4 考虑优化问题:

$$\begin{aligned}\min x_1 \\ \text{s.t. } 16 - (x_1 - 4)^2 - x_2^2 &\geq 0 \\ x_1^2 + (x_2 - 2)^2 - 4 &= 0\end{aligned}$$

1.4.1 写出上述问题的最优性条件, 计算 KKT 点.

已知优化问题:

$$\begin{cases} \min x_1 \\ \text{s.t. } 16 - (x_1 - 4)^2 - x_2^2 \geq 0 \\ x_1^2 + (x_2 - 2)^2 - 4 = 0 \end{cases}$$

因此可以构造拉格朗日函数: $L(x_1, x_2, \lambda_1, \lambda_2) = x_1 + \lambda_1(x_2^2 + (x_1 - 4)^2 - 16) + \lambda_2(x_1^2 + (x_2 - 2)^2 - 4)$

解得 KKT 条件为:

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial x_1} = 1 + 2\lambda_1(x_1 - 4) + 2\lambda_2 x_1 = 0 \\ \frac{\partial \mathcal{L}}{\partial x_2} = 2\lambda_1 x_2 + 2\lambda_2(x_2 - 2) = 0 \\ x_2^2 + (x_1 - 4)^2 - 16 \leq 0 \\ x_1^2 + (x_2 - 2)^2 - 4 = 0 \\ \lambda_1(x_2^2 + (x_1 - 4)^2 - 16) = 0 \\ \lambda_1 \geq 0 \end{cases}$$

解得:

$$\begin{cases} x_1^* = 0 \\ x_2^* = 0 \\ \lambda_1^* = -\frac{1}{8} \\ \lambda_2^* = 0 \end{cases} \text{ 或 } \begin{cases} x_1^* = \frac{8}{5} \\ x_2^* = \frac{12}{5} \\ \lambda_1^* = -\frac{1}{24} \\ \lambda_2^* = -\frac{1}{4} \end{cases}$$

因此 KKT 点为 (0,0) 和 $(\frac{8}{5}, \frac{12}{5})$.

1.4.2 判断上述 KKT 点是否是局部极小点, 鞍点, 或全局极小点.

对 1.4.1 中拉格朗日函数求二阶导:

$$\begin{cases} \frac{\partial^2 \mathcal{L}}{\partial x_1^2} = 2\lambda_1 + 2\lambda_2 \\ \frac{\partial^2 \mathcal{L}}{\partial x_2^2} = 2\lambda_1 + 2\lambda_2 \\ \frac{\partial^2 \mathcal{L}}{\partial x_1 \partial x_2} = \frac{\partial^2 \mathcal{L}}{\partial x_2 \partial x_1} = 0 \end{cases}$$

因此将 1.4.1 中的 KKT 点代入, 可求得 Hessian 矩阵为:

$$\begin{bmatrix} -\frac{1}{4} & 0 \\ 0 & -\frac{1}{4} \end{bmatrix} (\text{点 } (0,0)) \quad \begin{bmatrix} -\frac{7}{12} & 0 \\ 0 & -\frac{7}{12} \end{bmatrix} (\text{点 } (\frac{8}{5}, \frac{12}{5}))$$

检验可发现两个 Hessian 矩阵都是 $\succ 0$ 的, 但是将两个 KKT 点代入原式 $f(x)$ 中易得: 点 (0,0) 是极小点, 而点 $(\frac{8}{5}, \frac{12}{5})$ 为鞍点.

1.5 利用增广拉格朗日方法求解以下问题:

$$\begin{aligned} \min f(x) &= 2x_1^2 + x_2^2 - 2x_1x_2 \\ \text{s.t. } x_1 + x_2 &= 1. \end{aligned}$$

1.5.1 写出上述问题的最优性条件, 计算 KKT 点.

已知优化问题

$$\begin{cases} \min f(x) = 2x_1^2 + x_2^2 - 2x_1x_2 \\ \text{s.t. } x_1 + x_2 = 1. \end{cases}$$

因此可以构造拉格朗日函数： $L(x_1, x_2, \lambda) = 2x_1^2 + x_2^2 - 2x_1x_2 + \lambda(x_1 + x_2 - 1)$
解得 KKT 条件为：

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial x_1} = 4x_1 - 2x_2 + \lambda = 0 \\ \frac{\partial \mathcal{L}}{\partial x_2} = 2x_2 - 2x_1 + \lambda = 0 \\ x_1 + x_2 - 1 = 0 \\ \lambda \neq 0 \end{cases}$$

解得：

$$\begin{cases} x_1^* = \frac{2}{5} \\ x_2^* = \frac{3}{5} \\ \lambda^* = -\frac{2}{5} \end{cases}$$

所以 KKT 点为 $(\frac{2}{5}, \frac{3}{5})$

1.5.2 写出增广的拉格朗日函数.

易得增广拉格朗日函数如下：

$$\mathcal{P}_E(x_1, x_2, \lambda, \sigma) = 2x_1^2 + x_2^2 - 2x_1x_2 + \lambda(x_1 + x_2 - 1) + \frac{\sigma}{2}(x_1 + x_2 - 1)^2$$

1.5.3 令 $\sigma = 2, \lambda = 1$, 求解上述增广的拉格朗日函数的极小值.

由于 $\sigma = 2, \lambda = 1$, 所以将其代入 1.5.2 中的 $\mathcal{P}_E(x_1, x_2, \lambda, \sigma)$ 可得：

$$\begin{aligned} \mathcal{P}_E(x_1, x_2, \lambda, \sigma) &= 2x_1^2 + x_2^2 - 2x_1x_2 + \lambda(x_1 + x_2 - 1) + \frac{\sigma}{2}(x_1 + x_2 - 1)^2 \\ &= 2x_1^2 + x_2^2 - 2x_1x_2 + x_1 + x_2 - 1 + (x_1 + x_2 - 1)^2 \\ &= 2x_1^2 + x_2^2 - 2x_1x_2 + x_1 + x_2 - 1 + x_1^2 + x_1x_2 - x_1 + x_1x_2 \\ &\quad + x_2^2 - x_2 - x_1 - x_2 + 1 \\ &= 3x_1^2 + 2x_2^2 - x_1 - x_2 \end{aligned}$$

求上式偏导可得：

$$\begin{cases} \frac{\partial \mathcal{P}_E}{\partial x_1} = 6x_1 - 1 = 0 \\ \frac{\partial \mathcal{P}_E}{\partial x_2} = 4x_2 - 1 = 0 \end{cases}$$

解得：

$$\begin{cases} x_1^* = \frac{1}{6} \\ x_2^* = \frac{1}{4} \end{cases}$$

将其代入 \mathcal{P}_E 中，可得其极小值为 $-\frac{5}{24}$

1.5.4 计算修正的 λ .